

# Classificação de Câncer de Ovário utilizando Regressão Logística e Redução de Dimensionalidade (PCA)

Davi Israel Abtibol Carvalho

*PGENE556 - Aprendizado de Máquina*

*Programa de Pós-Graduação em Engenharia Elétrica (PPGEE - UFAM)*

Manaus, Amazonas, Brasil

davi.carvalho@ufam.edu.br

**Resumo**—Este trabalho apresenta o projeto e a avaliação de um classificador linear baseado em Regressão Logística para o diagnóstico precoce de câncer de ovário, a partir de dados de espectrometria de massa. Atendendo aos requisitos propostos, o conjunto de dados foi particionado em 80% para treinamento e 20% para teste. Para mitigar a alta dimensionalidade, a Análise de Componentes Principais (PCA) foi empregada, reduzindo as 100 características originais para as 50 mais representativas. Como resultado da validação, o algoritmo obteve um desempenho analítico perfeito, alcançando a marca de 100% em todas as três métricas monitoradas: acurácia, sensibilidade e especificidade.

**Index Terms**—Aprendizado de Máquina, Regressão Logística, PCA, Câncer de Ovário, Classificação.

## I. INTRODUÇÃO

O diagnóstico clínico preciso do câncer de ovário representa um obstáculo central na medicina preventiva, visto que sintomas manifestam-se predominantemente em estágios avançados. Na interface entre computação e biologia, técnicas de Aprendizado de Máquina vêm sendo amplamente desenvolvidas para processar exames de espectrometria de massa na busca de assinaturas proteômicas que confirmem a doença precocemente [1], [2].

O objetivo deste trabalho é projetar um regressor logístico de uma camada com a capacidade de classificar pacientes entre saudáveis e portadoras de câncer de ovário a partir dessas assinaturas moleculares. Dadas as múltiplas dimensões geradas pelos espectrômetros, o trabalho adota o conceito de redução de dimensionalidade para extrair apenas a porção matemática mais relevante dos dados. Para fins de avaliação, além da acurácia, a validação leva em conta a Sensibilidade e a Especificidade. A análise destas métricas secundárias atende a um critério rígido da área médica para evitar fenômenos de falsos negativos.

O restante do trabalho está organizado da seguinte forma: a Seção II descreve detalhadamente a base de dados utilizada, além das manipulações vetoriais e metodologias de treinamento. A Seção III exhibe e discute a separabilidade estatística e os resultados do classificador por meio das métricas exigidas. Por fim, as conclusões são traçadas na Seção IV.

## II. METODOLOGIA

### A. Materiais

A base de dados utilizada neste projeto consiste em informações extraídas pelo *Clinical Proteomics Program Databank* através de métodos de espectrometria de massa para análise de soro humano. A abordagem proteômica para identificação de câncer de ovário via padrões de biomarcadores foi pioneiramente proposta por [1], e posteriormente aprimorada por [2] com o uso de espectrometria de alta resolução, o que resultou em características de maior capacidade discriminatória.

Os dados em *ovarianInputs* são modelados na forma de uma matriz  $216 \times 100$ , retratando 100 níveis de intensidade iônica quantificados para distintos níveis de razão massa/carga, totalizando amostras de 216 pacientes. O conjunto alvo (*ovarianTargets*) dispõe da classificação confirmada desses pacientes: 121 apresentando câncer de ovário e 95 clinicamente atestados como normais.

Para acomodar o problema computacional a um classificador de natureza binária, o vetor alvo (originalmente *one-hot encoded*) foi simplificado, definindo matematicamente a classe de detecção positiva ( $y = 1$ ) aos pacientes adoecidos, e a classe negativa ( $Y = 0$ ) aos não doentes. Por fim, as 216 amostras foram fracionadas adotando uma proporção fixa de 80% de treinamento (172 pacientes) e 20% para a bateria de testes isolados (44 pacientes).

### B. Redução de Dimensionalidade (PCA)

Tendo em vista a alta dimensionalidade presente no espectro original ( $n = 100$ ), optou-se pela Análise de Componentes Principais (PCA) como ferramenta primária de redução.

Dado que os vetores principais do PCA são altamente suscetíveis à variação de amplitude do dado de entrada, todo o escopo de treinamento foi padronizado a possuir média aritmética nula e desvio padrão unitário. Ao reduzir a base computacional estritamente para 50 dimensões, apurou-se que 99,88% da variância original dos dados foi preservada, justificando matematicamente o uso prático da técnica.

### C. Regressão Logística e Métricas de Avaliação

O modelo de classificação escolhido foi a Regressão Logística com uma camada. Trata-se de um modelo estatístico linear que mapeia a combinação linear das características de entrada no intervalo probabilístico  $[0, 1]$  através da função de ativação Sigmoid.

Para proporcionar uma avaliação clínica robusta além da acurácia geral, o algoritmo foi avaliado considerando a Sensibilidade (taxa de detecção de pacientes com câncer) e a Especificidade (taxa de acerto em pacientes saudáveis). Tais métricas são extraídas da Matriz de Confusão segundo as equações matemáticas:

$$\text{Sensibilidade} = \frac{TP}{TP + FN} \quad (1)$$

$$\text{Especificidade} = \frac{TN}{TN + FP} \quad (2)$$

onde  $TP$  é o total de Verdadeiros Positivos,  $TN$  Verdadeiros Negativos,  $FP$  Falsos Positivos e  $FN$  Falsos Negativos.

### III. RESULTADOS E DISCUSSÕES

A predição do modelo Regressor Logístico no conjunto de teste de 44 amostras (composto por 25 pacientes com câncer e 19 normais) apresentou resultados superlativos, os quais encontram-se sumarizados na tabela I.

Tabela I  
RESULTADOS DAS MÉTRICAS DE AVALIAÇÃO NO CONJUNTO DE TESTE

| Métrica        | Desempenho (%) |
|----------------|----------------|
| Acurácia       | 100,00%        |
| Sensibilidade  | 100,00%        |
| Especificidade | 100,00%        |

A ausência total de erros (0 Falsos Positivos e 0 Falsos Negativos) indica que os biomarcadores retidos após o processamento com PCA são **linearmente separáveis** no hiperplano de 50 dimensões concebido pelo algoritmo. O comportamento analítico das classificações pode ser confirmado pela Matriz de Confusão perfeitamente diagonal demonstrada na Figura 1.

O alcance de 100% de *Sensibilidade* assegura que nenhuma paciente portadora de câncer foi dispensada equivocadamente, eliminando o erro mais crítico no diagnóstico assistido por computador. De maneira análoga, a *Especificidade* máxima assegura a ausência de alarme falso para pacientes saudáveis.

Para ilustrar o comportamento das características extraídas, foi plotado um gráfico de dispersão bidimensional abrangendo as duas primeiras componentes sintetizadas pelo PCA para o conjunto de treinamento (Figura 2).

Por intermédio desta análise visual, constata-se que as classes apresentam tendências de agrupamento em regiões distintas (pacientes saudáveis mais concentrados à direita e portadoras de câncer mais à esquerda). No entanto, nota-se uma nítida zona de sobreposição entre as nuvens de pontos. Este comportamento justifica perfeitamente a necessidade de retenção de múltiplas componentes: enquanto as duas primeiras dimensões




Figura 1. Matriz de Confusão do conjunto de teste (20%) confirmando 19 pacientes normais e 25 com câncer perfeitamente identificados.




Figura 2. Distribuição estatística das duas primeiras componentes principais do PCA (conjunto de treinamento). Nota-se uma clara tendência de agrupamento das classes, embora ainda exista sobreposição no espaço bidimensional. A separabilidade linear perfeita só é alcançada no hiperplano de 50 dimensões utilizado pelo classificador.

da variância não são suficientes para isolar as classes de forma irrestrita, a projeção do algoritmo no hiperplano de 50 dimensões torna os vetores linearmente separáveis. Deste modo, explica-se como o regressor logístico encontrou os limiares matemáticos para separar as classes com exatidão máxima de 100%, capitalizando sobre as informações contidas nas dimensões superiores que não são visíveis no plano 2D.

### IV. CONCLUSÃO

Este estudo evidenciou um êxito completo ao utilizar um classificador vetorial simples alinhado a uma etapa incisiva de pré-processamento para dados médicos complexos. Foi

comprovado que a compressão dos níveis químicos via Componentes Principais descarta o ruído e resguarda inteiramente o perfil matemático da doença (99,88% de conservação).

Além disso, atendeu-se ao desafio de expandir as métricas de acompanhamento, o que corroborou para a validade irrestrita do arranjo computacional proposto de Regressão Logística perante exigências do ramo da saúde (Sensibilidade perfeita sem geração de falsos diagnósticos positivos, refletidos na Especificidade máxima). Todo o material gerado em *Python* neste trabalho encontra-se acessível pelo GitHub: <https://github.com/AbtibolDavi/aprendizado-maquina-2026>.

#### REFERÊNCIAS

- [1] E. F. Petricoin III, A. M. Ardekani, B. A. Hitt, P. J. Levine, V. A. Fusaro, S. M. Steinberg, G. B. Mills, C. Simone, D. A. Fishman, E. C. Kohn, and L. A. Liotta, "Use of proteomic patterns in serum to identify ovarian cancer," *The Lancet*, vol. 359, no. 9306, pp. 572–577, Feb. 2002. [Online]. Available: [https://doi.org/10.1016/S0140-6736\(02\)07746-2](https://doi.org/10.1016/S0140-6736(02)07746-2)
- [2] T. P. Conrads, V. A. Fusaro, S. Ross, D. Johann, V. Rajapakse, B. A. Hitt, S. M. Steinberg, E. C. Kohn, D. A. Fishman, G. Whitely, J. C. Barrett, L. A. Liotta, E. F. Petricoin, and T. D. Veenstra, "High-resolution serum proteomic features for ovarian cancer detection," *Endocrine-Related Cancer*, vol. 11, no. 2, pp. 163–178, 2004. [Online]. Available: <https://erc.bioscientifica.com/view/journals/erc/11/2/15163296.xml>