

Previsão de Temperatura Máxima com Random Forest: Análise de Hiperparâmetros e Importância de Variáveis

Davi Israel Abtibol Carvalho

PGENE556 - Aprendizado de Máquina

Programa de Pós-Graduação em Engenharia Elétrica (PPGEE - UFAM)

Manaus, Amazonas, Brasil

davi.carvalho@ufam.edu.br

Resumo—Este trabalho apresenta o desenvolvimento e a avaliação de modelos de regressão não-lineares baseados no algoritmo Random Forest (Floresta Aleatória) para predição climática. Utilizando um histórico de observações meteorológicas da cidade de Seattle, foram projetados três arranjos computacionais distintos variando hiperparâmetros críticos com profundidade das árvores e uso de amostragem Booststrap. O estudo inclui a otimização automatizada via Busca Aleatória (Randomized Search) e uma análise do impacto de cada variável no processo decisório. Os resultados demonstram que modelos parcimoniosos obtiveram melhor capacidade de generalização, alcançando um Erro Absoluto Médio (MAE) de 3,67 graus, superando arquiteturas excessivamente profundas que demonstraram severo sobreajuste (overfitting).

Index Terms—Aprendizado de Máquina, Random Forest, Regressão, Hiperparâmetros, Previsão Climática.

I. INTRODUÇÃO

A previsão meteorológica é um desafio clássico de modelagem de sistemas complexos. Tradicionalmente abordada por equações diferenciais na física atmosférica, a previsão do tempo tem se beneficiado massivamente da introdução de técnicas de Aprendizado de Máquina, capazes de mapear padrões não-lineares a partir de dados históricos com grande eficiência computacional [1]. A base de dados utilizada neste estudo provém de registros históricos reais coletados pela Administração Oceânica e Atmosférica Nacional (NOAA) e estruturados para uso computacional [2]. Os dados representam uma série temporal contínua de parâmetros climáticos medidos na cidade de Seattle, estado de Washington (EUA). Diferentemente de classificadores clássicos, problemas climáticos lidam com espectros contínuos, caracterizando-se como tarefas de Regressão. Neste domínio, as métricas de acompanhamento diferem substancialmente, migrando da taxa de acertos para a quantificação da magnitude dos resíduos das predições. Diante deste contexto, o objetivo deste trabalho é avaliar o desempenho de três modelos de *Random Forest Regressor* na previsão da temperatura máxima diária. Secundariamente, busca-se otimizar os hiperparâmetros da arquitetura e quantificar, estatisticamente, a importância relativa de cada variável meteorológica na tomada de decisão dos algoritmos.

II. METODOLOGIA

A. Materiais

A base de dados adotada, referenciada no arquivo `temps_extended.xlsx`, dispõe de 2191 dias ininterruptos de registros meteorológicos. Deste escopo original, o trabalho delimitou analiticamente cinco variáveis independentes para a formulação do espaço de características vetorial (X):

- **year**: Ano do registro geológico.
- **ws_1**: Velocidade média do vento no dia anterior.
- **temp_2**: Temperatura máxima registrada dois dias antes.
- **temp_1**: Temperatura máxima registrada um dia antes.
- **average**: Histórico climatológico de média de temperatura.

O alvo estatístico (*target* - y) consiste na variável contínua actual, que representa a temperatura máxima real verificada no dia correspondente.

Atendendo ao rigor de avaliação de generalização, o conjunto total de 2191 amostras foi particionado em 75% para treinamento (1643 registros) e 25% para testes cegos (548 registros). É basilar ressaltar que não foi aplicada nenhuma técnica de padronização vetorial (como o *StandardScaler*). Como algoritmos baseados em Árvores de Decisão baseiam-se puramente em cortes de entropia ou redução de variância, eles são matematicamente imunes e invariantes à escala ou amplitude das características de entrada [3].

A Figura 1 exibe a análise exploratória conduzida nos materiais, revelando a altíssima interdependência entre a temperatura actual e a temperatura registrada no dia anterior.

B. Métodos e Parâmetros de Modelagem

O algoritmo empregado, *Random Forest*, é um método de *Ensemble Learning* que combina múltiplas árvores de decisão. Para mitigar vieses, baseia-se em dois estocásticos centrais: o *Bootstrap* (amostragem com reposição do conjunto de treino) e o sorteio aleatório de um subconjunto de características para a partição de cada nó [3]. Como regressão, a previsão final da floresta é resultante da média aritmética das predições de todas as suas árvores constituintes.

Matriz de Correlação: Variáveis Climáticas vs Target (actual)




Figura 1. Matriz de Correlação de Pearson entre as variáveis independentes e o alvo (actual). Nota-se fortíssima correlação de temp_1 e average.

Com o intuito de examinar o comportamento do algoritmo sob diferentes arquiteturas geométricas, três modelos foram instanciados:

- 1) **Modelo 1 (Conservador):** Estrutura controlada focada em combater o sobreajuste. Limitado a árvores rasas ($\text{max_depth} = 4$), com elevada exigência de amostras mínimas para a divisão de um nó ($\text{min_samples_split} = 10$) e para a formação de uma folha ($\text{min_samples_leaf} = 4$). Utilizou amostragem *Bootstrap* ativada e um total de 200 árvores ($\text{n_estimators} = 200$).
- 2) **Modelo 2 (Agressivo):** Permitiu-se o crescimento irrestrito das ramificações ($\text{max_depth} = 60$), com parâmetros frouxos de corte nas folhas ($\text{min_samples_leaf} = 1$) e baixa exigência de amostras para divisões internas ($\text{min_samples_split} = 2$). Houve desativação proposital do filtro estocástico de *Bootstrap* ($\text{bootstrap} = \text{False}$) e a floresta foi composta por 600 árvores ($\text{n_estimators} = 600$).
- 3) **Modelo 3 (Otimizado):** Fruto do uso de *RandomizedSearchCV*. O algoritmo buscou automatizada e exaustivamente a melhor combinação dentro do espaço de hiperparâmetros sugerido, guiando-se por validação cruzada (*3-Fold CV*). A melhor configuração encontrada e aplicada para avaliação foi: $\text{n_estimators} = 600$, $\text{max_depth} = 10$, $\text{min_samples_split} = 2$, $\text{min_samples_leaf} = 4$ e *Bootstrap* ativado.

C. Métricas de Avaliação

Ao invés do grau de classificação exata, as previsões numéricas foram avaliadas pelo Erro Absoluto Médio (MAE) e Erro Quadrático Médio (MSE), quantificados respectivamente pelas Equações (1) e (2):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2)$$

onde y_i é a temperatura real, $\hat{y}_i$ é a temperatura predita pela floresta e n é o total de amostras de teste. O coeficiente de determinação (R^2) também foi aferido para estimar o percentual de variância explicada pelo modelo.

III. RESULTADOS E DISCUSSÕES

A Tabela I condensa o desempenho final alcançado pelos três arranjos propostos perante as 548 amostras de teste.

Tabela I
DESEMPENHO DOS MODELOS NO CONJUNTO DE TESTE

Configuração	MAE (graus)	MSE	R ²
Modelo 1 (Conservador)	3,67	22,03	0,8643
Modelo 2 (Agressivo)	5,17	45,29	0,7210
Modelo 3 (Otimizado)*	3,74	22,67	0,8603

*Hiperparâmetros otimizados: $\text{n_estimators}=600$, $\text{max_depth}=10$, $\text{min_samples_split}=2$, $\text{min_samples_leaf}=4$, $\text{bootstrap}=\text{True}$.

A análise revela fenômenos clássicos do aprendizado estatístico. O Modelo 2 apresentou uma métrica analítica inaceitavelmente alta (MSE mais que o dobro dos demais). Trata-se de um caso manifesto de *overfitting*. Ao se permitir 60 níveis hierárquicos e a desativação da amostragem *Bootstrap*, as árvores memorizaram idiosincrasias do histórico de treino que não se repetiram no futuro, prejudicando brutalmente a predição.

Surpreendentemente, o desempenho do Modelo 1 obteve empate técnico e uma sutil vantagem em relação ao grandioso Modelo 3, otimizado por validação cruzada computacionalmente custosa. A justificativa encontra-se na linearidade latente imposta pela matriz de correlação prévia: uma floresta de 4 níveis de profundidade (Modelo 1) já engloba capacidade analítica suficiente para virar limiares nas variáveis determinantes, dispensando redes complexas.

Isso é categoricamente confirmado pelo relatório de extração de conhecimento exibido na Figura 2. Observando os gráficos, nota-se que a variável temp_1 detém mais de 80% do poder discriminatório no topo raiz das árvores para os modelos consistentes (Modelos 1 e 3), atestando a natureza correlacionada de que "a máxima de hoje depende criticamente da máxima de ontem". Por outro lado, o Modelo 2, que sofreu com *overfitting*, acaba distribuindo erroneamente uma relevância maior para ruídos do histórico. De maneira geral, percebe-se que fatores como o ano dos registros (year) e a velocidade do vento (ws_1) tiveram impactos matemáticos residuais mínimos na arquitetura de regressão.

IV. CONCLUSÃO

O presente trabalho confirmou a notável adaptabilidade das Florestas Aleatórias (*Random Forest*) na resolução de estimativas meteorológicas. A aplicação da técnica elucidou que o rigor cego nas hiperparametrização e a permissividade em florestas ultra-profundas conduzem invariavelmente ao desastre do *overfitting*. Modelos parcimoniosos provaram-se matematicamente mais polidos, identificando automaticamente e apoiando-se de modo confiável na imensa inércia térmica ditada pelo dia anterior do clima. O código de modelagem desenvolvido integra de forma irrestrita o repositório público do autor em <https://github.com/AbtibolDavi/aprendizado-maquina-2026>.

REFERÊNCIAS

- [1] A. McGovern, K. L. Elmore, D. J. Gagne, S. E. Haupt, C. D. Karstens, R. Lagerquist, T. Smith, and J. K. Williams, "Using artificial intelligence to improve real-time decision-making for high-impact weather," *Bulletin of the American Meteorological Society*, vol. 98, no. 10, pp. 2073 – 2090, 2017. [Online]. Available: <https://journals.ametsoc.org/view/journals/bams/98/10/bams-d-16-0123.1.xml>
- [2] National Oceanic and Atmospheric Administration (NOAA), "Climate data online: Seattle historical weather observations," 2016, extraído para processamento estatístico e simulação. [Online]. Available: <https://www.ncdc.noaa.gov/cdo-web/>
- [3] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct 2001. [Online]. Available: <https://doi.org/10.1023/A:1010933404324>




Figura 2. Importância relativa de cada variável na redução de impureza das decisões durante a construção das florestas. De cima para baixo: Modelo 1 (Conservador), Modelo 2 (Agressivo) e Modelo 3 (Otimizado).